

MVP - EXPECTATIVA DE VIDA E DESENVOLVIMENTO HUMANO

Pipeline de dados em nuvem e análise global no Databricks

Pós-graduação em Ciência de Dados e Analytics – PUC - Rio

MVP de Engenharia de Dados

Julia Neotti do Nascimento

2026

RESUMO

Este MVP apresenta a construção de um pipeline de dados em nuvem no Databricks para integrar indicadores internacionais de saúde, educação e desenvolvimento humano e analisar sua relação com a expectativa de vida. Foram utilizadas duas fontes públicas, persistidas em arquitetura Medallion nas camadas Bronze, Silver e Gold. O processamento incluiu avaliação de qualidade, padronização, tratamento de ausências, identificação de duplicidades, integração por país e ano e modelagem dimensional em esquema estrela. Para a análise, foi adotado o recorte de 2013, com 180 países na base integrada. Os resultados evidenciaram associação positiva forte entre escolaridade e expectativa de vida e associações negativas relevantes para mortalidade adulta e mortalidade relacionada ao HIV. O trabalho demonstra a aplicação integrada de conceitos de engenharia de dados, qualidade, modelagem e análise exploratória em ambiente de nuvem.

Palavras-chave: Databricks; engenharia de dados; expectativa de vida; desenvolvimento humano; qualidade de dados.

SUMÁRIO

1. Introdução	4
2. Dados, fontes e ferramentas.....	5
3. Metodologia de engenharia de dados	7
4. Modelagem dimensional	13
5. Resultados e discussão	15
6. Considerações finais.....	21
7. Reprodutibilidade e repositório	23
8. Referências e fontes de dados	25

1. INTRODUÇÃO

1.1 Contextualização e objetivo

A expectativa de vida é um indicador amplamente utilizado para representar as condições gerais de saúde e bem-estar de uma população. Entretanto, diferenças de longevidade entre países não dependem de um único fator, podendo estar associadas a aspectos educacionais, econômicos e epidemiológicos. Nesse contexto, a integração de bases provenientes de diferentes fontes permite analisar essas dimensões de forma conjunta e explorar possíveis relações entre desenvolvimento humano e condições de saúde.

O objetivo deste MVP é construir um pipeline de dados em nuvem capaz de integrar indicadores internacionais de saúde, educação e desenvolvimento socioeconômico e, a partir da base consolidada, analisar fatores associados às diferenças na expectativa de vida entre países no ano de 2013.

1.2 Perguntas analíticas

1. Como a expectativa de vida estava distribuída entre os países analisados em 2013?
2. Existem diferenças na expectativa de vida entre países classificados na fonte como desenvolvidos e em desenvolvimento?
3. Qual é a relação entre escolaridade e expectativa de vida?
4. Qual é a relação entre PIB per capita e expectativa de vida?
5. Quais indicadores de saúde apresentam maior associação com a expectativa de vida?
6. Como o IDH se relaciona com a expectativa de vida?
7. Quais países apresentaram os maiores e menores valores de expectativa de vida?

1.3 Escopo técnico

O projeto foi desenvolvido no Databricks e contempla as etapas de busca e documentação das fontes, armazenamento dos arquivos em nuvem, ingestão, avaliação da qualidade, transformação, integração e persistência dos dados.

O pipeline foi organizado segundo a arquitetura Medallion, com camadas Bronze, Silver e Gold. Na camada Gold, os dados integrados foram estruturados em um modelo dimensional em esquema estrela e posteriormente utilizados nas análises exploratórias desenvolvidas em Python e pandas.

O recorte de 2013 foi adotado por apresentar elevada cobertura simultânea entre as fontes utilizadas, especialmente para os indicadores de desenvolvimento humano. As bases completas foram preservadas nas camadas Bronze e Silver, enquanto o recorte temporal foi aplicado apenas na etapa de integração e construção da camada Gold, mantendo a rastreabilidade dos dados ao longo do pipeline.

2. DADOS, FONTES E FERRAMENTAS

2.1 Coleta das fontes de dados e licença de uso

Foram utilizadas duas fontes públicas e complementares, obtidas a partir de plataformas distintas. A primeira fonte foi o conjunto *Life Expectancy (WHO)*, disponibilizado na plataforma Kaggle, contendo informações internacionais de expectativa de vida, mortalidade, consumo de álcool, índice de massa corporal, PIB e outros indicadores relacionados à saúde. Para o projeto, foi utilizado o arquivo `WHO_life_expectancy.csv`.

A segunda fonte corresponde ao *Human Development Reports Data Center*, mantido pelo United Nations Development Programme (UNDP), do qual foram obtidos indicadores relacionados ao desenvolvimento humano e à educação. O arquivo utilizado no projeto, denominado `IDH.csv`, contém informações de Índice de Desenvolvimento Humano, índice de educação e anos médios de escolaridade.

Os arquivos foram obtidos a partir das páginas de disponibilização das respectivas fontes e preservados em seu formato tabular para posterior ingestão no Databricks. A coleta não envolveu geração de dados primários; foram utilizados dados secundários previamente publicados pelas instituições e plataformas responsáveis.

As duas bases apresentam as variáveis de identificação de país e ano, o que possibilitou sua integração posterior. Embora contenham indicadores de naturezas diferentes, sua combinação permite reunir, em uma mesma base analítica, informações de saúde, educação e desenvolvimento socioeconômico.

Os arquivos originais não são redistribuídos no repositório do projeto. Para garantir a reprodutibilidade, são documentados os links de origem, os nomes dos arquivos utilizados e as respectivas condições de uso.

Fonte	Arquivo	Conteúdo	Licença/condições de uso
Kaggle - Life Expectancy (WHO)	WHO_life_expectancy.csv	Expectativa de vida, mortalidade, álcool, IMC, PIB e indicadores de saúde	Domínio público - CC0 (Public Domain)
UNDP - Human Development Reports	IDH.csv	Escolaridade, índice de educação e Índice de Desenvolvimento Humano	Creative Commons Atribuição 3.0 IGO (CC BY 3.0 IGO)

Links de origem:

- <https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who/data>
- <https://hdr.undp.org/data-center/documentation-and-downloads>

2.2 Tecnologias utilizadas

O projeto foi desenvolvido no ambiente Databricks, utilizando recursos para armazenamento, processamento, persistência, análise e documentação dos dados. As principais tecnologias empregadas foram:

- **Databricks e Unity Catalog:** ambiente de desenvolvimento e organização dos objetos de dados;
- **Databricks Volumes:** armazenamento dos arquivos de origem;
- **Python e PySpark:** processamento e transformação dos dados;
- **Delta Lake:** persistência das tabelas;
- **pandas e NumPy:** manipulação e análise exploratória da base consolidada;
- **Matplotlib:** construção das visualizações;
- **GitHub:** versionamento e disponibilização do código e da documentação do projeto.

A utilização dessas tecnologias ao longo do pipeline é detalhada na Seção 3.

3. METODOLOGIA DE ENGENHARIA DE DADOS

3.1 Arquitetura do pipeline

A solução foi organizada segundo a arquitetura Medallion, com separação entre armazenamento dos dados de origem, tratamento e preparação analítica. Essa estrutura foi adotada para preservar os dados brutos, tornar as transformações rastreáveis e permitir que cada etapa do processamento utilizasse os resultados persistidos da etapa anterior.

A Figura 1 apresenta o fluxo implementado no Databricks, desde os arquivos de origem até a camada analítica final.




Figura 1 - Arquitetura do pipeline: Fontes → Volume → Bronze → Silver → Integração → Gold → Análise.


Fluxo principal:

- Volume: armazenamento dos arquivos CSV originais no ambiente Databricks;
- Bronze: persistência dos dados próximos ao formato de origem, sem aplicação de regras de limpeza;
- Silver: tipagem, padronização, tratamento de valores ausentes e criação de flags de qualidade;
- Integração: aplicação do recorte de 2013 e INNER JOIN entre as bases pela chave composta país + ano;
- Gold: organização dos dados integrados em modelo dimensional composto por dim_pais, dim_tempo e fato_saude_desenvolvimento;
- Análise: exploração estatística e construção das visualizações sobre a base consolidada.

3.2 Coleta, armazenamento e camada Bronze

O ambiente foi configurado no catálogo workspace e foram criados os schemas bronze, silver e gold, além do Volume workspace.bronze.raw_files para persistência dos arquivos de origem. Os arquivos WHO_life_expectancy.csv e IDH.csv foram carregados manualmente, por meio da interface do Databricks, nesse Volume. A presença dos arquivos no Volume foi confirmada pela interface do Databricks antes da etapa de ingestão. Em seguida, os arquivos foram lidos com PySpark e gravados como tabelas Delta na camada Bronze.

Nas camadas Bronze, Silver e Gold, os DataFrames resultantes foram persistidos como tabelas Delta no Databricks por meio de `saveAsTable()`, permitindo que os dados permanecessem armazenados e disponíveis para consulta após a execução dos notebooks.



The screenshot shows a Databricks notebook interface with two code cells. The first cell, titled '26 de ago. de 2026 (2s)', contains Python code to create three schemas: 'workspace.bronze', 'workspace.silver', and 'workspace.gold'. The second cell, titled '26 de ago. de 2026 (<1s)', contains a SQL query to show the existing schemas in the workspace. The output of the second cell is a table listing the schemas.

```
# Criar as camadas do Data Lakehouse
spark.sql("CREATE SCHEMA IF NOT EXISTS workspace.bronze")
spark.sql("CREATE SCHEMA IF NOT EXISTS workspace.silver")
spark.sql("CREATE SCHEMA IF NOT EXISTS workspace.gold")

print("Schemas Bronze, Silver e Gold criados com sucesso!")
```

```
# Verificar os schemas existentes no catálogo workspace
spark.sql("SHOW SCHEMAS IN workspace").show()
```

databaseName
bronze
default
gold
information_schema
silver

Figura 2 - Schemas Bronze, Silver e Gold criados no catálogo workspace.




Figura 3 - Volume raw_files criado para armazenamento dos arquivos brutos




Figura 4 - Arquivos brutos armazenados no Volume workspace.bronze.raw_files.




Figura 5 - Tabelas WHO e IDH persistidas na camada Bronze em formato Delta.

Dimensão das fontes na Bronze:

Conjunto	Registros	Atributos
WHO	2.938	10
IDH	5.336	5

A separação entre o armazenamento dos arquivos originais no Volume e sua posterior persistência como tabelas Bronze permite manter uma cópia dos dados de origem e, ao mesmo tempo, disponibilizá-los em formato adequado ao processamento no Databricks. Nenhuma regra de limpeza ou transformação foi aplicada nessa camada, de modo que a Bronze representa o ponto de entrada e referência dos dados utilizados no pipeline.

3.3 Qualidade dos dados e camada Silver

Antes da integração foi realizado um diagnóstico de qualidade sobre os dados preservados na Bronze. A avaliação considerou completude, unicidade da chave país-ano, domínios categóricos, adequação de tipos e presença de valores potencialmente inválidos.

3.3.1 Completude

Base	Atributo	Ausentes	Percentual
WHO	pib_dolar	448	15,25%
WHO	consumo_alcool	194	6,60%
WHO	IMC	34	1,16%
WHO	exp_vida	10	0,34%
WHO	mortalidade_adulta	10	0,34%
IDH	IDH	4.236	79,39%
IDH	anos_escolaridade_media	236	4,42%
IDH	indice_educacao	236	4,42%

A completude variou entre os atributos. Na base WHO, pib_dolar apresentou a maior proporção de valores ausentes (15,25%), enquanto expectativa de vida e mortalidade adulta apresentaram apenas 0,34% de ausência. Na base de desenvolvimento humano, o IDH apresentou elevada proporção de valores ausentes considerando toda a série histórica (79,39%), enquanto os indicadores educacionais apresentaram 4,42%.

A disponibilidade dos indicadores ao longo da série histórica foi considerada na definição do recorte de 2013, enquanto as ausências restantes foram consideradas na interpretação das análises posteriores.

3.3.2 Unicidade e validade

A avaliação de unicidade mostrou que a base WHO não apresentou chaves país-ano duplicadas. Na base IDH, por outro lado, foram identificadas 58 chaves duplicadas, correspondentes a 116 registros, concentradas em China e Congo. Também foram encontrados valores do índice de educação fora do intervalo esperado de 0 a 1, os quais foram sinalizados por meio de flags de qualidade.

Os dados originais foram preservados na camada Bronze. Na Silver, as inconsistências identificadas foram tratadas ou sinalizadas sem exclusão arbitrária de registros. Como algumas chaves duplicadas apresentavam valores conflitantes para a mesma combinação país-ano, não foi realizada deduplicação automática nessa etapa; a decisão sobre a utilização desses registros foi aplicada posteriormente, durante a integração. Essa abordagem permitiu manter a rastreabilidade entre os problemas detectados e as regras adotadas no pipeline.

3.3.3 Transformações realizadas na Silver

Na camada Silver, as variáveis numéricas originalmente armazenadas como texto foram convertidas para tipos numéricos, com substituição da vírgula decimal por ponto quando necessário. Os valores representados por NA e demais conteúdos não numéricos foram convertidos para NULL, o atributo países foi padronizado para país e o atributo ano foi convertido para tipo inteiro. Também foram criadas flags de qualidade para identificar registros inválidos, chaves duplicadas e valores do índice de educação fora do domínio esperado.

Os valores ausentes não foram imputados por média ou outras estimativas, pois esse procedimento poderia introduzir valores artificiais nas análises posteriores. A conversão para NULL preservou explicitamente a ausência de informação, enquanto o uso de flags permitiu manter a rastreabilidade das inconsistências identificadas e das regras aplicadas ao longo do pipeline.

Após as transformações e validações de qualidade, os DataFrames resultantes foram persistidos como tabelas Delta no schema silver, permanecendo disponíveis para utilização nas etapas seguintes do pipeline.

3.4 Integração e construção da camada Gold

Na construção da camada Gold foi aplicado o recorte de 2013. Registros associados a chaves ambíguas na base IDH foram excluídos da integração, enquanto valores inválidos do índice de educação foram convertidos para NULL, sem eliminar os demais atributos do registro.

Após a aplicação das regras de qualidade, a base WHO apresentava 193 registros em 2013 e a base IDH, 180 registros elegíveis. O INNER JOIN realizado pela chave composta país + ano resultou em uma base integrada com 180 países, sem duplicidades na chave final.

A combinação país + ano foi utilizada como chave de integração por representar o mesmo nível de granularidade nas duas fontes. A opção pelo INNER JOIN decorreu da necessidade de utilizar, nas

análises, apenas países com disponibilidade simultânea dos indicadores de saúde e desenvolvimento humano. Após a junção, a unicidade da chave foi novamente verificada para assegurar que o processo não tivesse provocado multiplicação indevida de registros.

Após a integração, os dados foram organizados nas tabelas `dim_pais`, `dim_tempo` e `fato_saude_desenvolvimento`, que foram persistidas em formato Delta no schema gold. A estrutura dimensional resultante é detalhada na Seção 4.

```

# Integrar as duas fontes utilizando país e ano como chave composta
df_integrado = ( df_who_2013 .join( df_idh_2013.select( "pais", "ano", "anos_escolaridade_media", "indice_educacao", "idh" ), on=["pais", "ano"], how="inner" ) )

# Verificar a dimensão do conjunto integrado
print("Registros integrados:", df_integrado.count())
print( "Países integrados:", df_integrado.select("pais").distinct().count() )

# Confirmar que o JOIN não criou duplicidades na chave país-ano
duplicatas_integracao = ( df_integrado .groupBy("pais", "ano") .count() .filter(F.col("count") > 1) .count() )
print("Chaves duplicadas após o JOIN:", duplicatas_integracao)
display(df_integrado.limit(10))

```

Ver desempenho (4) ✓ Verificado para melhorias

df_integrado: pyspark.sql.connect.dataframe.DataFrame = [pais: string, ano: integer ... mais 12 campos]

Registros integrados: 180
Países integrados: 180
Chaves duplicadas após o JOIN: 0

	país	ano	status	1.2 exp_vida	1.2 mortalidade_adulta	1.2 mortalidade_infantil	1.2 mortalidade_hiv	1.2 c
1	Afghanistan	2013	Developing	59.9	268	66	0.1	
2	Albania	2013	Developing	77.2	64	0	0.1	

Figura 6 — Validação da integração entre as bases WHO e IDH após o recorte de 2013.

4. MODELAGEM DIMENSIONAL

A camada Gold foi estruturada segundo um modelo dimensional em esquema estrela, no qual a tabela `fato_saude_desenvolvimento` concentra os indicadores quantitativos utilizados nas análises, enquanto as informações descritivas são organizadas nas dimensões `dim_pais` e `dim_tempo`.

A granularidade da tabela `fato` corresponde a um registro por país-ano. No recorte analítico adotado neste MVP, a dimensão temporal contém apenas o ano de 2013, mas sua manutenção no modelo preserva a estrutura dimensional e permite futura ampliação para outros períodos sem necessidade de alteração da arquitetura.

A relação entre a tabela `fato` e as dimensões é realizada por meio das chaves `id_pais` e `id_tempo`. Essa organização reduz a repetição de atributos descritivos e separa claramente os elementos de contexto dos indicadores utilizados nas análises.

Modelo Estrela — Camada Gold




Figura 7 - Esquema estrela da camada Gold.

A estrutura dimensional apresentada foi materializada no schema gold, conforme demonstrado na Figura 8.




Figura 8 — Tabelas dimensionais e tabela fato persistidas no schema gold do Databricks.

4.1 Catálogo de dados

O catálogo de dados foi documentado separadamente no arquivo docs/catalogo_dados.md do repositório do projeto, contendo descrição dos atributos, tipos, domínios, limites esperados, possibilidade de valores nulos, regras de qualidade e linhagem entre as fontes e a camada Gold.

As definições foram consolidadas a partir dos dicionários das fontes originais e das regras aplicadas durante o tratamento nas camadas Bronze e Silver. Os valores observados correspondem ao conjunto analítico final de 2013, enquanto os limites esperados representam critérios de validade definidos pelas fontes ou pelo próprio domínio dos indicadores. Essa documentação complementa o esquema dimensional apresentado nesta seção.

Tabela	Papel no modelo	Finalidade
dim_pais	Dimensão	Identificação do país e classificação de status.
dim_tempo	Dimensão	Ano de referência do conjunto analítico.
fato_saude_desenvolvimento	Tabela Fato	Indicadores de expectativa de vida, mortalidade, saúde, educação e desenvolvimento socioeconômico.

5. RESULTADOS E DISCUSSÃO

5.1 Perfil geral e status de desenvolvimento

5.1.1 Distribuição da expectativa de vida

Para responder à primeira pergunta do MVP, foram utilizadas estatísticas descritivas e a distribuição gráfica da expectativa de vida. A combinação entre média, mediana, valores mínimo e máximo e histograma permite observar tanto o nível central quanto a amplitude das diferenças existentes entre os países.

A base analítica contém 180 países, dos quais 176 possuem valor disponível de expectativa de vida. Em 2013, a expectativa média foi de 71,54 anos e a mediana de 73,5 anos, com valores entre 49,9 e 87 anos.

A mediana superior à média indica assimetria na distribuição, com os valores mais baixos contribuindo para reduzir a média em relação à mediana. Visualmente, o histograma mostra maior concentração de observações nas faixas mais elevadas de expectativa de vida, ao mesmo tempo em que permanece um grupo de países com valores substancialmente inferiores. Dessa forma, a média isolada não representa toda a diversidade observada no conjunto de dados.




Figura 9 - Distribuição da expectativa de vida em 2013.

5.1.2 Comparação segundo status de desenvolvimento

A segunda análise compara a expectativa de vida entre as categorias de status disponíveis na fonte. Foram utilizadas estatísticas agrupadas e um boxplot, permitindo comparar não apenas as médias, mas também a posição central e a dispersão dos valores em cada grupo.

Na categorização fornecida pela base, o grupo Developed apresentou média de 80,68 anos, enquanto o grupo Developing apresentou média de 69,50 anos. A comparação é exploratória e utiliza a classificação original disponibilizada na fonte.




Figura 10 - Expectativa de vida segundo status

A diferença entre as médias foi de aproximadamente 11,2 anos. O boxplot também evidencia maior dispersão entre os países classificados como Developing, enquanto o grupo Developed se concentra em valores mais elevados. O resultado indica uma associação descritiva entre a classificação de desenvolvimento e a longevidade, mas não permite atribuir essa diferença a um fator específico.

5.2 Educação, renda e expectativa de vida

5.2.1 Escolaridade e expectativa de vida

Para investigar a relação entre educação e longevidade, foi utilizada a correlação linear de Pearson entre os anos médios de escolaridade e a expectativa de vida, complementada por um gráfico de dispersão. Valores de correlação próximos de 1 indicam que as duas variáveis tendem a aumentar conjuntamente de forma linear.

A escolaridade apresentou uma das associações mais fortes com expectativa de vida. A correlação entre anos médios de escolaridade e expectativa de vida foi $r = 0,803$, indicando associação positiva forte.




Figura 11 - Relação entre anos médios de escolaridade e expectativa de vida em 2013.

O padrão ascendente dos pontos é coerente com o coeficiente encontrado: países com maior escolaridade média tendem, neste recorte, a apresentar maior expectativa de vida. Apesar da associação forte, existe dispersão entre países com níveis educacionais semelhantes, indicando que a escolaridade não explica isoladamente as diferenças de longevidade. Por se tratar de uma análise transversal e observacional, o resultado deve ser interpretado como associação e não como efeito causal da educação.

5.2.2 PIB per capita e expectativa de vida

A relação entre renda e longevidade foi analisada por meio do PIB per capita. Como essa variável apresenta distribuição assimétrica e grande amplitude entre os países, foi utilizada sua transformação logarítmica, reduzindo a influência visual dos valores extremos e facilitando a interpretação da relação. A correlação entre o log do PIB per capita e a expectativa de vida foi $r = 0,593$, indicando associação positiva moderada.




Figura 12 - Relação entre log do PIB per capita e expectativa de vida em 2013.

A relação positiva permanece visível após a transformação, porém com maior dispersão do que a observada para escolaridade. O coeficiente de 0,593 sugere que níveis econômicos mais elevados estão associados a maior expectativa de vida, mas que países com renda semelhante ainda podem apresentar resultados bastante diferentes. No conjunto analisado, portanto, a renda apresenta associação relevante, porém menos intensa do que os indicadores educacionais.

5.3 Indicadores associados à expectativa de vida

A tabela a seguir resume as correlações entre os principais indicadores quantitativos e a expectativa de vida. A interpretação considera a magnitude e a direção da associação; correlação não implica causalidade. As correlações foram calculadas utilizando, para cada indicador, os registros com valores disponíveis simultaneamente para as duas variáveis analisadas.

Para tornar a comparação entre os indicadores mais direta, os coeficientes foram ordenados pela magnitude absoluta da correlação. Assim, valores positivos representam variáveis que tendem a aumentar juntamente com a expectativa de vida, enquanto valores negativos representam associações em sentido oposto. Essa ordenação é exploratória e não corresponde a um ranking de importância causal, pois cada correlação é calculada separadamente e não controla a influência simultânea das demais variáveis.

Indicador	Correlação com expectativa de vida
IDH	0,893
Índice de educação	0,818
Anos médios de escolaridade	0,803
Mortalidade adulta	-0,717
Mortalidade relacionada ao HIV	-0,643
Log do PIB per capita	0,593
IMC	0,494
Consumo de álcool	0,483
Mortalidade infantil	-0,231

Entre os indicadores de saúde, a mortalidade adulta apresentou a associação de maior magnitude com a expectativa de vida ($r = -0,717$), seguida da mortalidade relacionada ao HIV ($r = -0,643$). A mortalidade infantil apresentou associação negativa mais fraca neste recorte ($r = -0,231$). Esses resultados indicam que os diferentes indicadores de saúde se relacionam de forma distinta com a longevidade e devem ser interpretados dentro do contexto do conjunto de dados.

O IDH apresentou a maior correlação positiva com a expectativa de vida ($r = 0,893$). Entretanto, esse resultado deve ser interpretado de forma complementar, pois a longevidade é uma das dimensões utilizadas na própria construção do IDH, tornando esperada parte dessa associação.

Os indicadores educacionais também apresentaram associações positivas fortes, com $r = 0,818$ para o índice de educação e $r = 0,803$ para os anos médios de escolaridade. O log do PIB per capita apresentou associação positiva moderada ($r = 0,593$).

As associações positivas observadas para IMC e consumo de álcool não devem ser interpretadas como efeitos benéficos ou relações causais, pois podem refletir diferenças de desenvolvimento, estrutura populacional e outros fatores de confusão não controlados nesta análise transversal.

5.4 Países com maiores e menores valores de expectativa de vida

Para complementar as análises agregadas, foram ordenados os países de acordo com a expectativa de vida e selecionados os dez maiores e os dez menores valores disponíveis. Essa abordagem permite visualizar de forma concreta a amplitude das diferenças entre países, sem substituir a análise dos fatores associados.

A análise dos extremos evidencia grandes diferenças entre os países no recorte estudado. Os valores observados variaram de 49,9 a 87 anos.

A diferença entre o maior e o menor valor observados foi de 37,1 anos, magnitude que evidencia a distância existente entre os extremos do conjunto analisado. No topo do ranking, Bélgica, Finlândia e

Reino Unido apresentaram 87 anos, enquanto a República Centro-Africana registrou o menor valor, com 49,9 anos.

Maiores valores	Expectativa de vida
Belgium	87,0
Finland	87,0
United Kingdom of Great Britain and Northern Ireland	87,0
Greece	86,0
Germany	86,0
Portugal	86,0
Slovenia	85,0
Japan	83,5
Switzerland	83,0
Singapore	82,7

Menores valores	Expectativa de vida
Central African Republic	49,9
Angola	51,1
Lesotho	52,1
Chad	52,2
Côte d'Ivoire	52,3
Nigeria	53,2
Sierra Leone	54,0
Mozambique	55,3
South Sudan	56,4
Cameroon	56,4

A amplitude observada reforça a heterogeneidade da longevidade entre os países analisados. Esses extremos devem ser interpretados em conjunto com as associações identificadas para educação, desenvolvimento econômico e indicadores de saúde, sem atribuir as diferenças observadas a uma única variável.

6. CONSIDERAÇÕES FINAIS

6.1 Conclusão

A análise dos dados de 2013 evidenciou diferenças expressivas na expectativa de vida entre os países avaliados. Os indicadores educacionais apresentaram algumas das associações positivas mais fortes com a longevidade, destacando-se o índice de educação e os anos médios de escolaridade. O PIB per capita também apresentou associação positiva, enquanto a mortalidade adulta e a mortalidade relacionada ao HIV apresentaram associações negativas relevantes.

As perguntas propostas foram respondidas de forma exploratória. A expectativa de vida apresentou ampla variação entre os países, diferiu entre as categorias de status disponibilizadas pela fonte e mostrou associações consistentes com indicadores educacionais, econômicos e de saúde. O IDH apresentou a maior correlação positiva observada, embora esse resultado deva ser interpretado com cautela, uma vez que a longevidade compõe o próprio índice.

Além dos resultados analíticos, o MVP demonstrou a implementação de um pipeline de dados em nuvem no Databricks, contemplando armazenamento dos arquivos de origem, ingestão com Spark/PySpark, avaliação e tratamento da qualidade dos dados, integração entre fontes, persistência em tabelas Delta e construção de um modelo dimensional na camada Gold. Dessa forma, o projeto reuniu etapas de engenharia e análise de dados em um fluxo único, rastreável e reproduzível.

6.2 Limitações

O projeto utiliza um recorte transversal referente ao ano de 2013, permitindo identificar associações, mas não estabelecer relações de causalidade ou avaliar a evolução temporal dos indicadores. Também foram observados valores ausentes em alguns atributos e problemas de unicidade na base de desenvolvimento humano, considerados durante as etapas de qualidade e integração do pipeline.

As análises realizadas são predominantemente descritivas e bivariadas e, portanto, não controlam simultaneamente possíveis fatores de confusão. Além disso, os resultados dependem das definições, classificações e da disponibilidade dos dados nas fontes originais, devendo ser interpretados dentro desses limites.

6.3 Autoavaliação e trabalhos futuros

Os principais objetivos delineados para o MVP foram atingidos. Foi possível construir e documentar um pipeline de dados em nuvem contemplando ingestão, organização em camadas Bronze, Silver e Gold, avaliação da qualidade, integração de fontes, persistência em tabelas Delta, modelagem dimensional e análise exploratória dos indicadores.

As principais dificuldades estiveram relacionadas à transformação de atributos numéricos originalmente armazenados como texto, ao tratamento de valores ausentes, à identificação de chaves

duplicadas e à integração de bases com diferentes características de preenchimento. A resolução dessas questões exigiu a definição explícita de regras de qualidade e integração, buscando preservar a rastreabilidade dos dados e evitar decisões arbitrárias durante o tratamento.

Como trabalhos futuros, o pipeline pode ser ampliado para incorporar outros anos, permitindo análises longitudinais e a avaliação da evolução temporal dos indicadores. Também podem ser incluídas novas fontes de dados e aplicadas técnicas estatísticas inferenciais e modelos multivariados, capazes de avaliar conjuntamente as associações entre os diferentes indicadores e a expectativa de vida.

7. REPRODUTIBILIDADE E REPOSITÓRIO

O código completo e a documentação do projeto foram organizados em um repositório público no GitHub. Os notebooks devem ser executados sequencialmente, pois cada etapa utiliza os artefatos persistidos pela anterior.

Repositório: <https://github.com/julianeotti/mvp-expectativa-vida-databricks>

Notebook	Conteúdo
00_configuracao_mvp.ipynb	Configuração do ambiente, criação dos schemas e do Volume.
01_ingestao_bronze.ipynb	Leitura dos arquivos CSV e criação das tabelas Bronze.
02_qualidade_e_silver.ipynb	Diagnóstico de qualidade, transformação, padronização e persistência das tabelas Silver.
03_integracao_e_gold.ipynb	Recorte de 2013, integração das fontes, construção do modelo dimensional e persistência da Gold.
04_analise_e_conclusoes.ipynb	Construção da base analítica, análises estatísticas, visualizações e interpretação dos resultados.

Documentação complementar:

- docs/catalogo_dados.md
- docs/arquitetura_pipeline.png
- docs/modelo_estrela.png

Reprodução do pipeline:

Para reproduzir o projeto, é necessário obter os arquivos WHO_life_expectancy.csv e IDH.csv a partir das fontes indicadas na Seção 2 e carregá-los no Volume workspace.bronze.raw_files do Databricks. Após essa etapa, os notebooks devem ser executados na ordem numérica apresentada acima. A execução recria os schemas, tabelas Delta das camadas Bronze, Silver e Gold e, por fim, as análises desenvolvidas sobre a base consolidada.

Estrutura final do repositório:

```
mvp-expectativa-vida-databricks/  
├── README.md  
├── 00_configuracao_mvp.ipynb  
├── 01_ingestao_bronze.ipynb  
├── 02_qualidade_e_silver.ipynb  
├── 03_integracao_e_gold.ipynb  
├── 04_analise_e_conclusoes.ipynb  
├── MVP_Expectativa_Vida_Databricks.pdf  
├── docs/  
│   ├── catalogo_dados.md  
│   ├── arquitetura_pipeline.png  
│   └── modelo_estrela.png
```

O catálogo de dados apresenta descrições, tipos, domínios, valores esperados, regras de qualidade e linhagem dos atributos utilizados na camada Gold.

8. REFERÊNCIAS E FONTES DE DADOS

KAGGLE. Life Expectancy (WHO). Disponível em: <https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who/data>. Acesso em: 22 ago. 2026. Licença: CC0 - domínio público.

UNITED NATIONS DEVELOPMENT PROGRAMME (UNDP). Human Development Reports - Data Center: documentation and downloads. Disponível em: <https://hdr.undp.org/data-center/documentation-and-downloads>. Acesso em: 22 ago. 2026. Licença: Creative Commons Attribution 3.0 IGO (CC BY 3.0 IGO).